Modelamiento Bayesiano de la Criminalidad mediante Procesos de Conteo con Offset Demográfico en Chicago

Bamsi Mendez Posada
Universidad Nacional de Colombia, sede Manizales

Resumen

Este trabajo propone un marco bayesiano para modelar la criminalidad en las 77 áreas comunitarias de Chicago mediante modelos de conteo con offset poblacional. Se comparan cinco especificaciones Poisson y Binomial Negativa utilizando inferencia HMC/NUTS en Stan y criterios de selección WAIC y PSIS-LOO. La evidencia favorece un modelo Binomial Negativa capaz de capturar la sobredispersión observada y proporcionar inferencias interpretables sobre los efectos socioeconómicos. Finalmente, se compara su capacidad predictiva contra modelos de Machine Learning y se presenta una simulación contrafactual que ilustra el potencial del modelo para apoyar decisiones de políticas públicas.

Objetivos

Objetivo general: desarrollar un marco bayesiano de modelos de conteo con offset poblacional para cuantificar la asociación entre factores socioeconómicos y la criminalidad en las áreas comunitarias de Chicago.

Objetivos específicos:

1. Formular y ajustar cinco especificaciones Poisson y Binomial Negativa con offset poblacional mediante inferencia HMC/NUTS en Stan.
2. Seleccionar el modelo con mejor capacidad predictiva y estabilidad numérica mediante los criterios WAIC y PSIS-LOO.
3. Interpretar los efectos de pobreza, desempleo e ingreso per cápita sobre la tasa esperada de crimen bajo el modelo seleccionado.
4. Contrastar el desempeño predictivo del modelo bayesiano frente a algoritmos de Machine Learning de referencia.
5. Ilustrar, mediante una simulación contrafactual, el potencial del modelo para orientar decisiones de política pública.

Planteamiento del Problema y Datos

Pregunta central: ¿Por qué algunas áreas comunitarias presentan mayores tasas de crimen que otras, condicionado a su población y su entorno socioeconómico?

Unidad de análisis: $n = 77$ áreas comunitarias de Chicago. Variable respuesta y_i: conteo total de crímenes. Dado que los conteos brutos crecen con la población N_i, se incorpora esta como término de **exposición (offset)** en el predictor lineal:

$$\log(\mu_i) = \log(N_i) + \beta_0 + \sum_{j=1}^{p} \beta_j x_{ji}$$

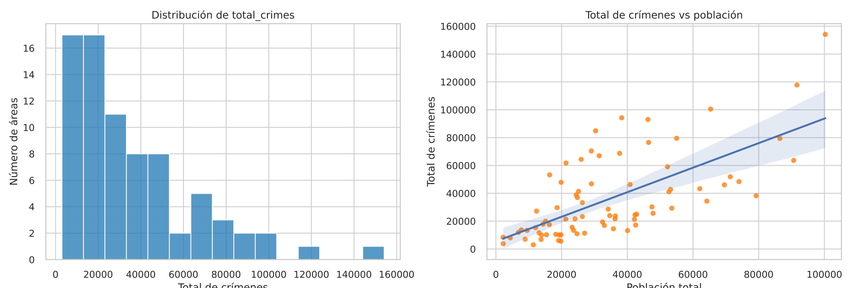
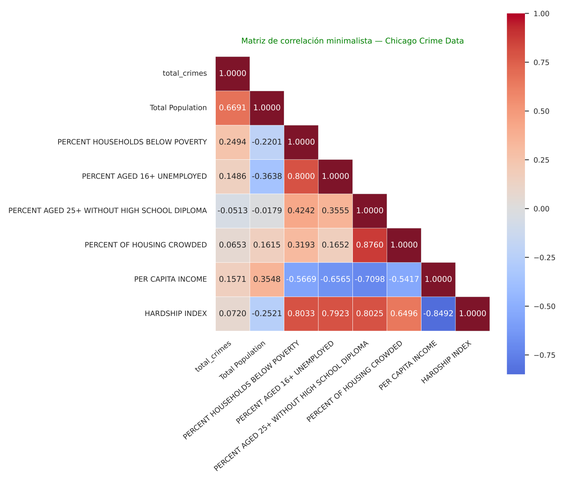


Figura 1:Distribución de crímenes totales y su relación con la población: se evidencia la necesidad del offset logarítmico.

Metodología: Datos, Colinealidad y Especificación

1. **Auditoría de colinealidad (VIF):** se detectó redundancia severa del *Hardship Index* (VIF > 10) por ser un índice compuesto de las demás covariables; se excluye permanentemente y se conservan Pobreza, Desempleo e Ingreso Per Cápita, estandarizadas (z-score).
2. **Cinco especificaciones:** M1–M3 (Poisson, equidispersión) y M4–M5 (Binomial Negativa, con parámetro de dispersión ϕ), todas con offset poblacional y priors débilmente informativos $\beta_j \sim \mathcal{N}(0, 1)$, $\phi \sim \text{Gamma}(2, 0.1)$.
3. **Inferencia:** HMC/NUTS en Stan (`cmdstanpy`), 4 cadenas, 1000 warmup + 1000 muestreo (4000 draws post-warmup).



(a) Correlación

	Variable	VIF
0	Total Population	1.481784
1	PERCENT HOUSEHOLDS BELOW POVERTY	5.528878
2	PERCENT AGED 16+ UNEMPLOYED	7.793986
3	PERCENT AGED 25+ WITHOUT HIGH SCHOOL DIPLOMA	11.438454
4	PERCENT OF HOUSING CROWDED	5.865027
5	PER CAPITA INCOME	4.622212
6	HARDSHIP INDEX	35.922919

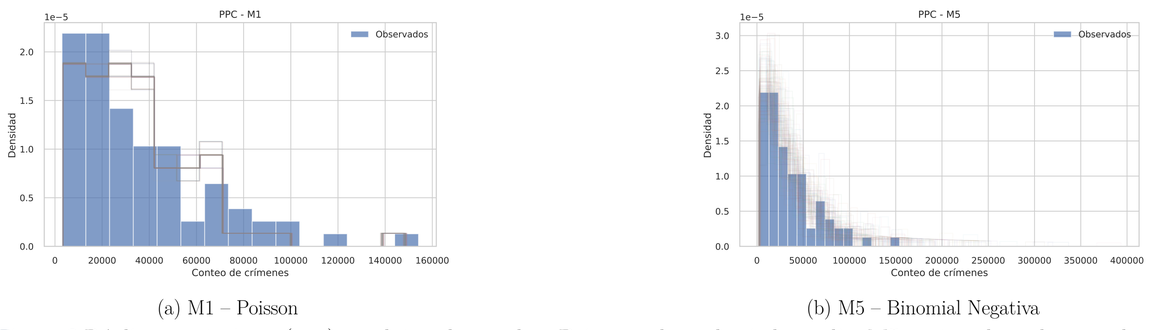
(b) VIF

Figura 2:Correlación entre covariables y Factor de Inflación de la Varianza: base de la exclusión del Hardship Index.

Diagnóstico de Convergencia y Chequeo Predictivo Posterior

Las 5 cadenas convergieron sin problemas: $\hat{R} < 1.01$ en todos los parámetros, ESS (Bulk y Tail) > 400, y **cero** transiciones divergentes en las 5 especificaciones.

El PPC revela la insuficiencia de la familia Poisson frente a la sobredispersión real de los datos:



(a) M1 – Poisson

(b) M5 – Binomial Negativa

Figura 3:Réplicas posteriores (y_{rep}) vs. datos observados: Poisson colapsa hacia la media; M5 captura las colas pesadas.

Selección Formal de Modelos (WAIC / PSIS-LOO)

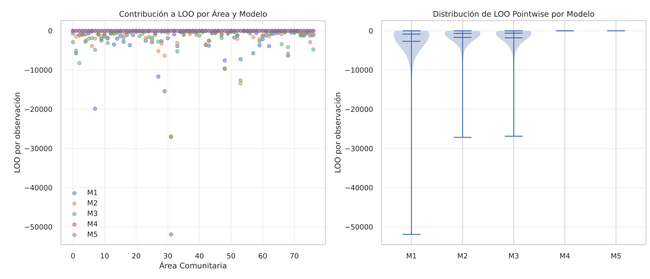
Modelo	elpd_loo	Δelpd	SE	WAIC
M5 (Bin. Neg.)	**-811.45**	**0.00**	12.45	**1622.90**
M4 (Bin. Neg.)	-824.12	-12.67	11.80	1648.24
M2 (Poisson)	-131,071.15	-130,259.70	4,512.10	262,142.30
M3 (Poisson)	-138,410.90	-137,599.45	4,890.32	276,821.80
M1 (Poisson)	-145,201.30	-144,389.85	5,102.11	290,402.60

Tabla 1:Matriz comparativa de selección formal. M5 domina por más de 130,000 unidades de elpd frente a Poisson.

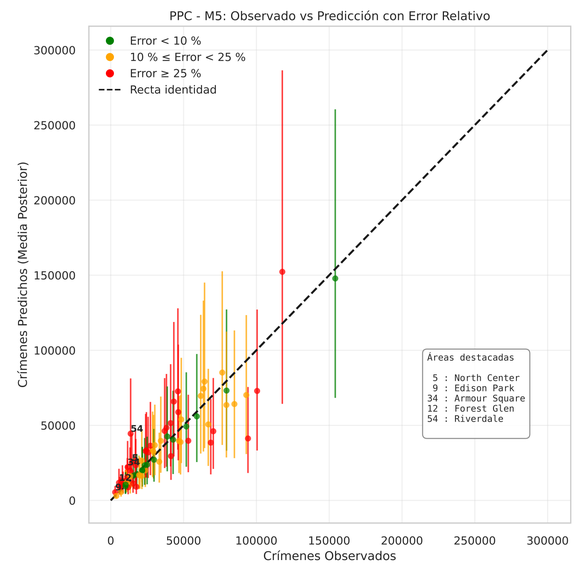
Figura 4:Comparación de densidad predictiva logarítmica esperada (elpd_loo) con errores estándar por modelo.

Validación de Estabilidad: Diagnóstico Pareto $\hat{k}$

Los modelos Poisson exhiben entre 61 y 67 de las 77 áreas con $\hat{k} \geq 1.0$ (varianza infinita en la importancia por muestreo). **M5 registra cero** observaciones en zona de peligro, con 97.4% de las áreas en $\hat{k} < 0.5$, sustentado en $\phi = 4.12$ [IC95%: 3.20, 5.15].



(a) Contribución al error LOO por área



(b) Observado vs. predicción (M5)

Figura 5:Estabilidad de M5: sin observaciones en zona de peligro $\hat{k}$, mayoría de áreas con error $< 10\%$.

Interpretación de Efectos Socioeconómicos (Modelo M5)

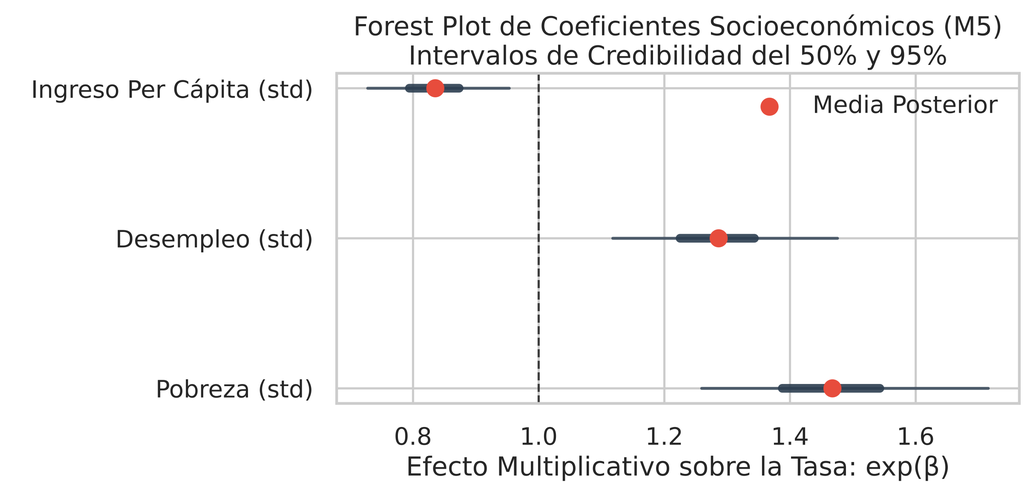


Figura 6:Forest plot: coeficientes posteriores y su efecto multiplicativo $\exp(\beta_j)$ sobre la tasa de crimen.

- **Pobreza:** +1 DE ⇒ tasa de crimen ×1.46 (**+46%**).
- **Desempleo:** +1 DE ⇒ tasa de crimen ×1.28 (**+28%**).
- **Ingreso per cápita:** +1 DE ⇒ tasa de crimen ×0.83 (**-17%**).

Contraste Predictivo frente a Machine Learning

Modelo	MAE	RMSE	R^2	MAPE
Gradient Boosting	8,502.94	11,254.42	0.774	34.98%
Bayesiano (M5)	**8,536.87**	12,378.57	0.726	40.41%
Random Forest	11,448.57	14,569.17	0.621	51.60%
Ridge Regression	12,348.60	16,497.80	0.514	66.44%

Tabla 2:M5 queda a solo 34 delitos (MAE) del mejor algoritmo de ML, ofreciendo además incertidumbre honesta.

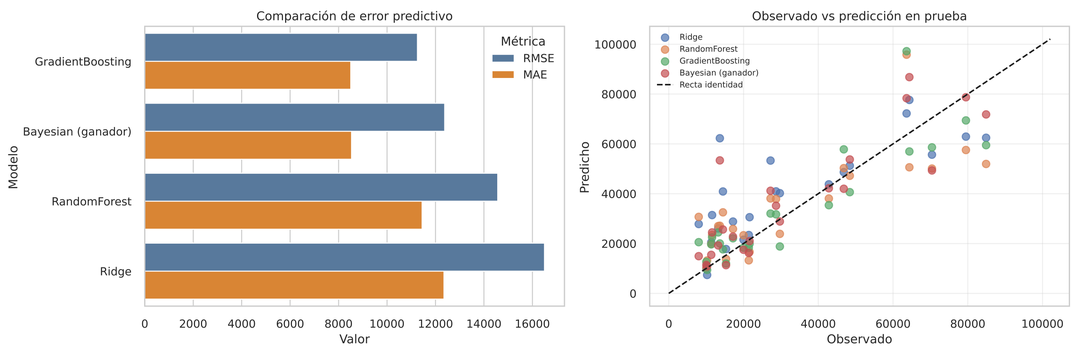


Figura 7:Métricas de error y dispersión observado vs. predicho: M5 frente a los algoritmos de referencia.

Simulación Contrafactual: Impacto en Política Pública

Reduciendo el desempleo en 1.5 DE en las 5 áreas más vulnerables, el modelo proyecta una contracción del **31.3%** en la tasa esperada de delitos en todas ellas (propagando las 4,000 muestras posteriores), equivalente a prevenir cerca de **25,000** delitos en South Lawndale y **14,000** en North Lawndale.

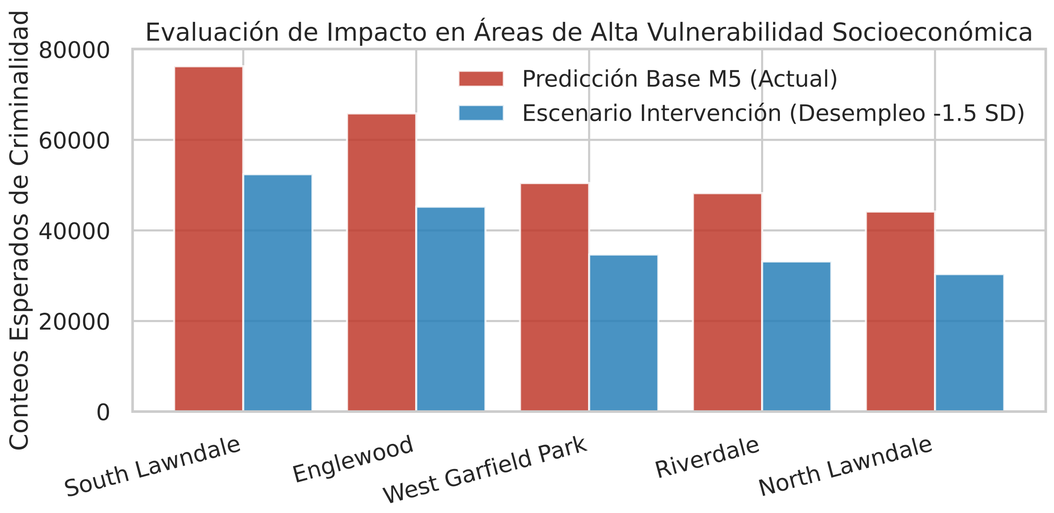


Figura 8:Escenarios contrafactuales por área comunitaria: predicción base vs. post-intervención.

Conclusiones

- La Binomial Negativa con offset (M5) es la única especificación teóricamente defendible: absorbe la sobredispersión que colapsa a Poisson (evidenciado por WAIC, PSIS-LOO y $\hat{k}$ de Pareto).
- Pobreza y desempleo son los principales impulsores de la tasa de crimen; el ingreso per cápita actúa como factor protector.
- M5 iguala casi el desempeño predictivo de Gradient Boosting, con la ventaja de propagar incertidumbre honesta e interpretabilidad causal.
- La simulación contrafactual demuestra utilidad directa para priorizar intervenciones socioeconómicas focalizadas.
- Trabajo futuro: extensión jerárquica espacial (BYM2) para modelar la autocorrelación geográfica residual detectada en el suroeste de la ciudad.

Referencias

- Gelman, A., et al. (2013). *Bayesian Data Analysis* (3rd ed.). CRC Press.
- Vehtari, A., Gelman, A., & Gabry, J. (2017). Practical Bayesian model evaluation using LOO and WAIC. *Statistics and Computing*, 27(5), 1413–1432.
- Betancourt, M. (2018). A conceptual introduction to Hamiltonian Monte Carlo. *arXiv:1701.02434*.
- Hilbe, J. M. (2011). *Negative Binomial Regression* (2nd ed.). Cambridge University Press.